Dictionnaire de données — NovaTel

Dataset pédagogique Télécom · Modèle en étoile · BigQuery · Looker Studio

Formation Data Analyst — Simplon 2026 · Version 2 (dataset validé)

1. Contexte — NovaTel

NovaTel est un opérateur télécom fictif qui commercialise des offres mobiles, fibre, box, terminaux et accessoires via quatre canaux : boutiques propres, franchises, web et téléphone.

Ce jeu de données pédagogique couvre le 1er janvier 2023 au 31 décembre 2024 et simule l'activité commerciale et financière d'un opérateur de taille nationale.

2. Modèle de données — Étoile strict

La table fact_transactions est au centre. Cinq dimensions y sont directement rattachées. Aucune dimension ne dépend d'une autre.

Table	Relation avec fact_transactions
`fact_transactions`	**Table centrale du modèle en étoile**
`dim_client`	FK client_id → fact_transactions
`dim_produit`	FK produit_id → fact_transactions
`dim_date`	FK date_id → fact_transactions
`dim_point_vente`	FK point_vente_id → fact_transactions
`dim_type_operation`	FK type_operation_id → fact_transactions

3. Volumes

Table	Lignes	Rôle
fact_transactions	246 853	Table de faits — une ligne = une opération commerciale ou financière
dim_client	10 150	Clients (dont ~150 doublons volontaires)
dim_produit	50	Produits et offres du catalogue NovaTel
dim_point_vente	30	Points de vente et canaux de distribution
dim_date	731	Calendrier 2023-2024
dim_type_operation	8	Types et catégories d'opérations

Détail de fact_transactions :

Type d'opération	Lignes	Notes
Souscriptions (TOP01)	20 004	8 % annulées, 92 % validées
Facturations mensuelles (TOP02)	197 144	6 % impayées — générées pour chaque mois actif

Ventes terminaux (TOP03)	12 003	12 % annulées
Ventes accessoires (TOP04)	10 002	7 % annulées
Remboursements (TOP05)	2 000	montant_net négatif
Avoirs commerciaux (TOP06)	1 500	montant_net négatif
Résiliations (TOP07)	3 000	impact_ca neutre
Annulations vente (TOP08)	1 200	montant_net = 0
Anomalies injectées	50	doublons + post-résiliation

4. Dictionnaire de données

fact_transactions

Colonne	Type	Clé	Description	Exemple	Nullable
transaction_id	STRING	PK	Identifiant unique de la transaction	TXN0000001	Non
date_id	STRING	FK → dim_date	Clé de date YYYYMMDD	20230415	Oui*
client_id	STRING	FK → dim_client	Identifiant du client	CLI00042	Non
produit_id	STRING	FK → dim_produit	Identifiant du produit	PRD003	Non
point_vente_id	STRING	FK → dim_pv	Identifiant du point de vente	PV001	Non
type_operation_id	STRING	FK → dim_type_op	Type d'opération	TOP01	Non
quantite	INTEGER	—	Quantité concernée	1	Non
montant_brut	FLOAT	—	Montant avant remise et remboursement	49.99	Non
remise	FLOAT	—	Montant de remise appliqué	5.00	Non
remboursement	FLOAT	—	Montant remboursé (avoirs, retours)	0.00	Non
montant_net	FLOAT	—	montant_brut – remise – remboursement (0 si annulée)	44.99	Non
montant_encaisse	FLOAT	—	Montant réellement encaissé (0 si impayé/annulé)	44.99	Non
statut_transaction	STRING	—	validée / annulée / impayée / remboursée	validée	Non

dim_client

Colonne	Type	Clé	Description	Exemple	Nullable
client_id	STRING	PK	Identifiant unique du client	CLI00001	Non
prenom	STRING	—	Prénom	Lucas	Non
nom	STRING	—	Nom de famille	Martin	Non
email	STRING	—	Adresse email	lucas.martin@g	Oui*

			(anomalies présentes)	mail.com	
sexe	STRING	—	M / F (quelques valeurs incohérentes)	M	Non
date_naissance	DATE	—	Date de naissance	1985-06-22	Non
tranche_age	STRING	—	18-25 / 26-35 / 36-45 / 46-55 / 56-65 / 65+	26-35	Non
ville	STRING	—	Ville de résidence	Lyon	Non
region	STRING	—	Région administrative (NULL sur ~200 lignes)	Auvergne-Rhône-Alpes	Oui*
segment_client	STRING	—	Grand public / Professionnel / Étudiant / Senior / Famille	Grand public	Non
date_entree_client	DATE	—	Date de création du compte	2020-03-15	Non

dim_produit

Colonne	Type	Clé	Description	Exemple	Nullable
produit_id	STRING	PK	Identifiant unique du produit	PRD001	Non
nom_produit	STRING	—	Nom commercial	Forfait Mobile M 60Go	Non
categorie_produit	STRING	—	Mobile / Fibre / Box / Terminal / Accessoire	Mobile	Non
sous_categorie	STRING	—	Sous-catégorie détaillée	Forfait SIM	Non
marque	STRING	—	Marque (NovaTel, Apple, Samsung, NovaAcc)	NovaTel	Non
prix_catalogue	FLOAT	—	Prix unitaire achat (0 pour abonnements)	399.99	Non
prix_mensuel	FLOAT	—	Prix mensuel abonnement (0 pour équipements)	19.99	Non
engagement_mois	INTEGER	—	Durée d'engagement en mois (0 = sans engagement)	24	Non
statut_produit	STRING	—	actif / inactif	actif	Non

dim_point_vente

Colonne	Type	Clé	Description	Exemple	Nullable
point_vente_id	STRING	PK	Identifiant unique	PV001	Non

nom_point_vente	STRING	—	Nom du point de vente	NovaTel Paris Opéra	Non
type_point_vente	STRING	—	Boutique propre / Franchise / Web / Téléphone	Boutique propre	Non
ville	STRING	—	Ville (National pour web/téléphone)	Paris	Non
region	STRING	—	Région (vide pour canaux nationaux)	Île-de-France	Oui
canal	STRING	—	boutique propre / franchise / web / téléphone	boutique propre	Non

dim_date

Colonne	Type	Clé	Description	Exemple	Nullable
date_id	STRING	PK	Clé YYYYMMDD	20230601	Non
date	DATE	—	Date ISO complète	2023-06-01	Non
jour	INTEGER	—	Numéro du jour (1-31)	1	Non
jour_semaine	STRING	—	Lundi / Mardi / … / Dimanche	Jeudi	Non
numero_mois	INTEGER	—	Numéro du mois (1-12)	6	Non
nom_mois	STRING	—	Janvier / … / Décembre	Juin	Non
trimestre	STRING	—	T1 / T2 / T3 / T4	T2	Non
annee	INTEGER	—	2023 ou 2024	2023	Non
weekend	STRING	—	Oui / Non	Non	Non

dim_type_operation

Colonne	Type	Clé	Description	Exemple	Nullable
type_operation_id	STRING	PK	Identifiant du type	TOP01	Non
type_operation	STRING	—	Souscription / Facturation / Vente terminal / Vente accessoire / Remboursement / Avoir / Résiliation / Annulation vente	Souscription	Non
categorie_operation	STRING	—	Abonnement / Equipement / Avoir	Abonnement	Non
impact_ca	STRING	—	positif / négatif / neutre	positif	Non

5. Anomalies volontairement injectées

Les anomalies suivantes ont été introduites pour être détectées et traitées par les apprenants lors de l'exploration dans BigQuery.

Table	Type d'anomalie	Quantité exacte	Description
dim_client	Doublons client	150	Même personne avec deux client_id distincts (même email)
dim_client	Email manquant	~300	Champ email vide
dim_client	Email malformé	~100	Email sans @ (ex: lucas.martingmail.com)
dim_client	Région manquante	~200	Champ region vide
dim_client	Casse incohérente	~100	Segment en majuscules (ex: GRAND PUBLIC)
dim_client	Sexe incohérent	~50	Valeur N ou vide au lieu de M/F
fact_transactions	Date manquante	246	date_id vide (0,10 % des lignes)
fact_transactions	Montant brut aberrant	142	montant_brut multiplié par ×10 à ×50 — entraîne un écart montant_brut / montant_net détectable
fact_transactions	Montant net négatif	75	montant_net négatif sur une opération non remboursement (0,03 %)
fact_transactions	Statut incohérent	50	statut=validée mais montant_encaisse=0 (0,02 %)
fact_transactions	Doublons transaction_id	30	Lignes identiques avec même transaction_id
fact_transactions	Facturations post-résiliation	50	Facturations générées après la date de résiliation du contrat

Note sur les incohérences montant_brut / montant_net :

217 lignes présentent un écart entre montant_brut − remise − remboursement et montant_net. Ce sont toutes des anomalies pédagogiques volontaires : 142 montants bruts aberrants (montant_brut modifié après calcul du net) + 75 montants nets négatifs hors remboursements. Aucune incohérence structurelle non voulue n'est présente.

6. Règles métier appliquées

- Une vente validée contribue au CA brut et au CA encaissé.
- Une vente annulée : montant_net = 0 et montant_encaisse = 0. Elle ne contribue pas au CA.
- Une vente impayée contribue au CA facturé (montant_net > 0) mais pas à l'encaissé (montant_encaisse = 0).
- Un remboursement (TOP05) ou avoir (TOP06) a un impact_ca 'négatif' : montant_net < 0.
- Une résiliation (TOP07) a un impact_ca 'neutre' : montant_net = 0, pas d'écriture financière.
- montant_net = montant_brut − remise − remboursement (sauf si annulée → 0).

- montant_encaisse = montant_net si validée, 0 si annulée ou impayée.
- Les facturations mensuelles sont générées pour chaque mois entre la date de souscription et la résiliation (ou fin de période).
- Les souscriptions annulées ne génèrent aucune facturation.
- Les produits inactifs n'apparaissent dans aucune transaction.
- Les ventes de terminaux se font uniquement en boutique, franchise ou web (pas téléphone).
- CA encaissé ≤ CA net hors annulées (vérifié lors de l'audit).

7. Chiffres clés du dataset (post-validation)

Indicateur	Valeur
CA brut (hors annulées)	13 070 594 €
CA net (hors annulées)	12 226 009 €
CA encaissé	12 193 313 €
Total remises	227 037 €
Total remboursements	355 572 €
Impayés	392 540 €
CA enc ≤ CA net	OUI ✅
FK invalides	0 ✅
Incompatibilités type op × produit	0 ✅
Ventes terminaux via téléphone	0 ✅
Transactions sur produits inactifs	0 ✅

8. Exemples de questions métier réalisables

- Quel est le CA brut, net et encaissé par mois sur 2024 ?
- Quelle est la répartition des ventes par canal de distribution ?
- Quels sont les 5 produits les plus vendus en valeur ?
- Quelle est la performance de chaque région en CA net ?
- Quel est le montant total des remises par catégorie de produit ?
- Combien de clients ont au moins un impayé, et quel est le montant total ?
- Quelle est la répartition des souscriptions par segment client ?
- Quels points de vente ont le panier moyen le plus élevé sur les terminaux ?
- Combien de transactions ont un montant_net négatif sans être des remboursements ? (anomalie)
- Combien de clients apparaissent en doublon dans dim_client ? (qualité données)
- Combien de facturations ont eu lieu après la résiliation du contrat ? (anomalie)